


ДОМАШНЕЕ ЗАДАНИЕ

Аналитика данных



ЧТО ТЕБЕ НУЖНО ЗНАТЬ?

3

БЛОКА ЗАДАНИЙ

19.06

ДЕДЛАЙН

Мы ждем от тебя один любой полностью решенный блок заданий для дальнейшего участия в конкурсе.

При желании ты можешь сделать несколько блоков или все— мы обязательно это учтем при оценке.

Первый блок заданий по аналитике данных

Аналитика музыкального стримингового сервиса mosMusic

Вводная часть

mosMusic — это наш смелый музыкальный стартап, который пытается бодро конкурировать с другими гигантами на рынке.

У нас не такой огромный каталог, зато у нас есть свои фишки: выдающиеся аналитические возможности, которые позволяют видеть, кто что слушает, когда и на каком устройстве.

Твоя миссия: стать настоящим Data-детективом в мире музыки, прокачивая навыки SQL и BI.

Блок 1: состоит из пяти задач

Задача 1: Выбери самый прослушиваемый Rock-альбом

Найди альбом, в котором суммарное количество прослушиваний песен в жанре Rock самое большое.

Формат вывода: album (TEXT), artist (TEXT), listens (INTEGER)

Задача 2: Кто в топ-20% по хитам

Определи исполнителя, у которого больше всего песен в топ-20% по количеству прослушиваний.

Формат вывода: artist (TEXT), top_songs (INTEGER)

Задача 3: Альбом с самой крутой коллаборацией

Найди альбом, в котором больше всего песен с несколькими артистами. В ответе покажи название альбома, основного исполнителя и количество совместных песен.

Формат вывода: album (TEXT), artist (TEXT), collab_count (INTEGER)

Задача 4: Динамика прослушиваний по месяцам

Составь таблицу с суммарным количеством прослушиваний по месяцам для всех песен.

Формат вывода: year_month (TEXT, формат YYYY-MM), total_listens (INTEGER)

Задача 5: Популярность жанров по регионам

Составь сводную таблицу с суммарным количеством прослушиваний по жанрам и регионам.

Формат вывода: genre (TEXT), region (TEXT), total_listens (INTEGER)

Блок 1

Совет профи:

Начни с маленьких выборок, чтобы понять структуру данных и потом постепенно наращивай SQL-запросы с JOIN, CTE и оконными функциями.

Блок 1

Техническая инструкция

Файл базы данных:

mosmusic_final_collabs_multiple_albums.db

Формат: SQLite

Как открыть: используй любой из двух
SQL-клиентов:

SQLite

DBeaver

После открытия можно выполнять SQL-запросы,
строить сводные таблицы и дашборды.

Удачи! 🍀



Датасет для задач блока 1

Сканируй QR-код или **переходи по ссылке**

Блок 1

Описание таблиц

artists: artist_id, name, country — уникальный ID артиста, имя и страна.

albums: album_id, title, artist_id, release_year — уникальный ID альбома, название, ID основного артиста, год выпуска.

songs: song_id, title, album_id, release_year — уникальный ID песни, название, альбом, год выпуска.

song_artists: song_id, artist_id — связь песни и исполнителя (для коллабораций несколько записей на песню).

genres: genre_id, name — уникальный ID жанра, название жанра.

song_genres: song_id, genre_id — связь песни и жанра (песня может иметь несколько жанров).

listening_logs: user_id, song_id, listen_time, device, region — пользователь, песня, время прослушивания, устройство, регион (субъект РФ).

Второй блок заданий по аналитике данных

Блок 2: состоит из четырех задач

Задача 1.

Дана таблица посещаемости сервиса по месяцам. Проанализируй исторические данные и спрогнозируй количество пользователей на следующие 12 месяцев.

Dataset: `newborns_stats.csv`

Задача 2.

Цепочки ID:

Условие: Даны две таблицы: `users (id, new_id)` и `links (id1, id2)`, описывающие историю изменений ID одного пользователя (например, $1 \rightarrow 2 \rightarrow 3$).

Используй два подхода к решению:
рекурсивный и нет.

Задание: На основе связей определи для каждого исходного ID единый финальный `new_id` (минимальный ID в цепочке) и дедублируй записи.

Ожидаемый результат: `id -> new_id`
(например, $1, 2, 3, 5 \rightarrow 1$; $4 \rightarrow 4$; $7, 8 \rightarrow 7$).

Задача 3.

Очистка строк:

Условие: Дана таблица `data (id, name)`. В поле `name` перемешаны визуально одинаковые кириллические и латинские символы (а/а, о/о, с/с и т.д.).

Задание: Приведи имена к единому виду (к одной системе письма), затем найди дубликаты и присвой каждой группе дублей новый `new_id`.

Задача 4.

Симметричные пары:

Условие: Дана таблица `items (id, name, category)`.

Задание: Найди все пары записей, у которых полностью совпадают `name` и `category`. Пары (`id1, id2`) и (`id2, id1`) считай идентичными (оставь только одну). Пары с одинаковыми ID необходимо исключить.

Ожидаемый результат: `id1, id2, category`.

Блок 2

Датасет для
задач блока 2



Сканируй QR-код или [переходи по ссылке](#)

Третий блок заданий по аналитике данных

Цель задания проверить твои навыки:

- работа с Python и обработкой данных
- понимание ETL/ELT-процессов
- умение работать с грязными данными
- базовые знания DWH-моделирования
- навыки SQL

Блок 3

Тебе предоставляется набор источников данных в разных форматах: CSV, JSON, XLSX, XML. Данные содержат информацию о клиентах, заказах, товарах, платежах и событиях пользовательской активности.

Стек

1. Python 3.10+
2. pandas / pyspark
3. PostgreSQL
4. SQLAlchemy / psycopg2
5. Docker (опционально)

Задача

Необходимо построить end-to-end ETL-пайплайн: от загрузки сырых данных до аналитических SQL-запросов.

Итог

Ссылка на архив или Git-репозиторий со следующей структурой:

```
project/  
|-- src/  
|-- sql/  
|-- ddl/  
|-- data/  
|-- requirements.txt  
|-- README.md  
|-- docker-compose.yml (опционально)
```

Блок 3

НАБОР ФАЙЛОВ

data/
|-- customers.csv
|-- orders.json
|-- products.xlsx
|-- events.xml
|-- payments.csv



Датасет для задач блока 3
Сканируй QR-код или [переходи по ссылке](#)

Блок 3: состоит из пяти заданий

Задание 1. Загрузка данных:

- Считать данные из всех источников
- Привести данные к единому формату
- Выполнить базовую очистку
- Загрузить данные в БД

Задание 2. Data Quality: Необходимо обработать ошибки, описать принятые решения и логировать проблемные записи.

Задание 3. DWH-модель: Необходимо спроектировать и реализовать DWH-модель.

Допустимые варианты:

- Star Schema
- Data Vault (упрощённый вариант)

Минимальные сущности: клиенты, товары, заказы, платежи, события

Задание 4. SQL-аналитика: Необходимо написать SQL-запросы

- Топ-10 клиентов по сумме покупок
- Выручка по месяцам
- Самые популярные товары
- Последняя активность (дата) топ-5 пользователей, которые совершили больше всего покупок
- Пользователи без заказов

5. Документация: Необходимо предоставить README с описанием:

- Как запускать проект
- Структура проекта
- Архитектурные решения
- Как воспроизвести результат

Дополнительно*: Инкрементальная загрузка, Airflow и Unit-тесты

Результат

Важно

Для того, чтобы передать результат домашнего задания, **создай папку в любом облачном хранилище** и направь нам ссылку по шаблону на следующем слайде.

ИИ при выполнении заданий

Мы не против использования ИИ при выполнении заданий, но будет здорово, если **ты поделишься ссылками на диалоги**, где велась работа над задачами.

Нам интересно посмотреть, как ты взаимодействуешь и мыслишь вместе с нейросетью.

Для этого создай файл **«Общение с ИИ»** в облаке с выполненным ДЗ, и добавь в него ссылки твоей коммуникации с нейросетью.

Мы ждем от тебя один* выполненный блок заданий до 12:00 19 июня на почту:

DIT_student@it.mos.ru

Как назвать письмо?

Тема: Аналитика данных _ДЗ_ФИО кандидата
(например: Аналитика данных _ДЗ_Иванов Иван Иванович)

Что должно быть в письме:

Ссылка на облако с файлами

Перед отправкой еще раз проверь:

- **тему письма**
- **ссылку на файлы или работу**
- **доступы на просмотр**

*При желании и наличии времени, ты можешь сделать два или три блока заданий. Это обязательно повысит твои шансы пройти на стажировку! 😊



Отбор. Что будет дальше?



До 19 июня

Мы будем принимать ДЗ по почте
DIT_student@it.mos.ru



До 24 июля

Мы будем проверять работы и назначать интервью
с наставниками по итогам выполнения ДЗ



После 24 июля

Вернемся с результатами отбора

